LoRA：大型语言模型的低秩适配

爱德华·胡* 沈烨龙* 菲利普·沃利斯 曾泽元 李远志 王世安 王璐 陈伟柱

微软公司 {edwardhu, yeshe, phwallis, zeyuana, yuanzhil, swang, luw, wzchen}@microsoft.com yuanzhil@andrew.cmu.edu（版本2）

摘要

自然语言处理的一个重要范式包括在通用领域数据上进行大规模预训练，并适应特定任务或领域。随着我们预训练更大的模型，全量微调（即重新训练所有模型参数）变得不那么可行。以GPT-3 175B为例——部署独立的微调模型实例，每个实例拥有175B参数，成本高昂得令人望而却步。我们提出了低秩适应（Low-Rank Adaptation，简称LoRA），它冻结预训练模型的权重，并将可训练的秩分解矩阵注入Transformer架构的每一层，从而大幅减少下游任务的可训练参数数量。与使用Adam微调的GPT-3 175B相比，LoRA可以将可训练参数数量减少10,000倍，并将GPU内存需求降低3倍。尽管LoRA的可训练参数更少、训练吞吐量更高，并且与适配器不同，*no additional inference latency*，但它在RoBERTa、DeBERTa、GPT-2和GPT-3上的模型质量表现与微调相当或更好。我们还对语言模型适应中的秩亏现象进行了实证研究，这为LoRA的有效性提供了启示。我们发布了一个便于将LoRA与PyTorch模型集成的软件包，并在https://github.com/microsoft/LoRA提供了我们在RoBERTa、DeBERTa和GPT-2上的实现和模型检查点。

1 引言

自然语言处理中的许多应用依赖于将*one*大规模预训练语言模型适配到*multiple*下游应用。这种适配通常通过*fine-tuning*完成，它会更新预训练模型的所有参数。微调的主要缺点是新模型包含的参数数量与原模型一样多。随着每隔几个月就有更大的模型被训练出来，这已从对GPT-2（Radford等，b）或RoBERTa large（Liu等，2019）而言仅仅是“不便”，转变为对拥有1750亿可训练参数的GPT-3（Brown等，2020）而言的关键部署挑战。[1]

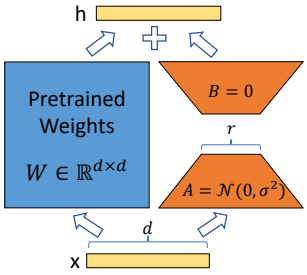


图1：我们的重参数化。我们仅训练 A 和 B。

许多人试图通过仅调整部分参数或为新任务学习外部模块来缓解这一问题。这样一来，我们只需为每个任务存储和加载少量任务特定参数以及预训练模型，从而在部署时大幅提升运行效率。然而，现有技术

*Equal contribution.

[0]Compared to V1, this draft includes better baselines, experiments on GLUE, and more on adapter latency.

[1]While GPT-3 175B achieves non-trivial performance with few-shot learning, fine-tuning boosts its performance significantly as shown in Appendix A.

arXiv:2106.09685v2 [cs.LG] 16 Oct 2021

通常会通过扩展模型深度来引入推理延迟（Houlsby et al., 2019; Rebuffi et al., 2017），或减少模型可用的序列长度（Li & Liang, 2021; Lester et al., 2021; Hambardzumyan et al., 2020; Liu et al., 2021）（第3节）。更重要的是，这些方法往往无法与微调基线相匹配，从而在效率和模型质量之间形成权衡。

我们从Li等人（2018a）；Aghajanyan等人（2020）中获得灵感，他们表明学习到的过参数化模型实际上位于低内在维度上。我们假设模型适应过程中权重的变化也具有低“内在秩”，从而提出了我们的低秩适应（LoRA）方法。LoRA允许我们通过优化适应过程中密集层变化的秩分解矩阵，间接训练神经网络中的一些密集层，同时保持预训练权重冻结，如图1所示。以GPT-3 175B为例，我们表明即使全秩（即d）高达12,288，非常低的秩（即图1中的r可以是一或二）也足够，使LoRA在存储和计算上都很高效。

LoRA 具有几个关键优势。

- 一个预训练模型可以被共享，并用于构建许多针对不同任务的小型LoRA模块。我们可以冻结共享模型，并通过替换图1中的矩阵A和B来高效地切换任务，从而显著降低存储需求和任务切换开销。
- LoRA 使训练更加高效，并在使用自适应优化器时将硬件入门门槛降低多达 3 倍，因为我们不需要为大多数参数计算梯度或维护优化器状态。相反，我们只优化注入的、小得多的低秩矩阵。
- 我们简单的线性设计允许我们在部署时将可训练矩阵与冻结权重合并，*introducing no inference latency* 与完全微调的模型相比，这是由构造决定的。
- LoRA与许多先前的方法正交，并且可以与其中许多方法结合，例如前缀调优。我们在附录E中提供了一个示例。

术语与约定 我们频繁引用Transformer架构，并使用其维度的常规术语。我们将Transformer层的输入和输出维度大小称为d_{model}。我们使用W_q、W_k、W_v和W_o来指代自注意力模块中的查询/键/值/输出投影矩阵。W或W_0指代预训练权重矩阵，ΔW指代其在适应过程中的累积梯度更新。我们使用r表示LoRA模块的秩。我们遵循(Vaswani et al., 2017; Brown et al., 2020)所设定的惯例，并使用Adam(Loshchilov & Hutter, 2019; Kingma & Ba, 2017)进行模型优化，并使用Transformer MLP前馈维度$d_{ffn} = 4 \times d_{model}$。

2 问题陈述

虽然我们的提案与训练目标无关，但我们重点关注语言建模作为激励性的用例。以下是语言建模问题的简要描述，特别是给定任务特定提示下条件概率的最大化。

假设我们给定一个预训练的自回归语言模型 $P_\Phi(y|x)$，其参数为 Φ。例如，$P_\Phi(y|x)$ 可以是基于 Transformer 架构（Vaswani 等，2017）的通用多任务学习器，如 GPT（Radford 等，b；Brown 等，2020）。考虑将此预训练模型适配到下游条件文本生成任务，如摘要、机器阅读理解（MRC）和自然语言到 SQL（NL2SQL）。每个下游任务由上下文-目标对的训练数据集表示：$\mathcal{Z} = \{(x_i, y_i)\}_{i=1,..,N}$，其中 x_i 和 y_i 均为 token 序列。例如，在 NL2SQL 中，x_i 是自然语言查询，y_i 是其对应的 SQL 命令；对于摘要，x_i 是文章内容，y_i 是其摘要。

在完全微调期间，模型被初始化为预训练权重Φ_0，并通过反复跟随梯度以最大化条件语言建模目标，更新为$\Phi_0 + \Delta\Phi$：

$$\max_{\Phi} \sum_{(x,y)\in\mathcal{Z}} \sum_{t=1}^{|y|} \log\left(P_{\Phi}(y_t|x, y_{<t})\right) \tag{1}$$

完全微调的主要缺点之一是，对于*each*下游任务，我们学习一组*different*参数$\Delta\Phi$，其维度$|\Delta\Phi|$等于$|\Phi_0|$。因此，如果预训练模型很大（例如GPT-3有$|\Phi_0| \approx$1750亿参数），存储和部署许多独立的微调模型实例即使可行，也可能具有挑战性。

在本文中，我们采用了一种更参数高效的方法，其中任务特定的参数增量 $\Delta\Phi = \Delta\Phi(\Theta)$ 由一组规模小得多的参数 Θ 进一步编码，且 $|\Theta| \ll |\Phi_0|$。因此，寻找 $\Delta\Phi$ 的任务转变为对 Θ 进行优化：

$$\max_{\Theta} \sum_{(x,y)\in\mathcal{Z}} \sum_{t=1}^{|y|} \log\left(p_{\Phi_0+\Delta\Phi(\Theta)}(y_t|x, y_{<t})\right) \tag{2}$$

在后续章节中，我们提出使用低秩表示来编码$\Delta\Phi$，这种表示在计算和内存上都很高效。当预训练模型为GPT-3 175B时，可训练参数数量$|\Theta|$可以小至$|\Phi_0|$的0.01%。

3 现有解决方案还不够好吗?

我们要解决的问题绝非新问题。自迁移学习诞生以来，已有数十项工作致力于使模型适应在参数和计算上更加高效。关于一些知名工作的综述，请参见第6节。以语言建模为例，在高效适应方面有两种显著策略：添加适配器层（Houlsby et al., 2019; Rebuffi et al., 2017; Pfeiffer et al., 2021; Rücklé et al., 2020）或优化某种形式的输入层激活（Li & Liang, 2021; Lester et al., 2021; Hambardzumyan et al., 2020; Liu et al., 2021）。然而，这两种策略都有其局限性，尤其是在大规模且对延迟敏感的生产场景中。

适配器层引入推理延迟 适配器有许多变体。我们聚焦于Houlsby等人（2019）的原始设计，其每个Transformer块有两个适配器层，以及Lin等人（2020）更近期的设计，其每个块只有一个适配器层但增加了额外的LayerNorm（Ba等人，2016）。虽然可以通过剪枝层或利用多任务设置（Rücklé等人，2020；Pfeiffer等人，2021）来减少整体延迟，但没有直接方法绕过适配器层中的额外计算。这似乎不是问题，因为适配器层通过具有小的瓶颈维度而被设计为具有少量参数（有时为原始模型的<1%），这限制了它们可以增加的FLOPs。然而，大型神经网络依赖硬件并行性来保持低延迟，而适配器层必须顺序处理。这在在线推理设置中会产生差异，其中批量大小通常小至一。在没有模型并行性的通用场景中，例如在单个GPU上对GPT-2（Radford等人，b）medium运行推理，我们看到使用适配器时延迟明显增加，即使瓶颈维度非常小（表1）。

当我们需要像Shoeybi等人（2020）和Lepikhin等人（2020）那样对模型进行分片时，这个问题会变得更严重，因为额外的深度需要更多的同步GPU操作，如AllReduce和Broadcast，除非我们多次冗余存储适配器参数。

直接优化提示是困难的。另一个方向，如前缀调优（Li & Liang, 2021）所示，面临着不同的挑战。我们观察到前缀调优难以优化，并且其性能在可训练参数中非单调变化，这证实了原论文中的类似观察。更根本的是，为适应保留一部分序列长度必然会减少可用于处理下游任务的序列长度，我们怀疑这使得调优提示相比其他方法性能更低。我们将关于任务性能的研究推迟到第5节。

Batch Size Sequence Length $\|\Theta\|$	32 512 0.5M	16 256 11M	1 128 11M
Fine-Tune/LoRA	1449.4±0.8	338.0±0.6	19.8±2.7
$\text{Adapter}^{\text{L}}$	1482.0±1.0 (+2.2%)	354.8±0.5 (+5.0%)	23.9±2.1 (+20.7%)
$\text{Adapter}^{\text{H}}$	1492.2±1.0 (+3.0%)	366.3±0.5 (+8.4%)	25.8±2.2 (+30.3%)

表1：在GPT-2 medium中单次前向传递的推理延迟，以毫秒为单位，在100次试验中取平均值。我们使用的是NVIDIA Quadro RTX8000。“$|\Theta|$”表示适配器层中可训练参数的数量。$\text{Adapter}^{\text{L}}$和$\text{Adapter}^{\text{H}}$是适配器调优的两种变体，我们在第5.1节中描述。适配器层引入的推理延迟在在线、短序列长度的场景中可能非常显著。完整研究见附录B。

4 我们的方法

我们描述了LoRA的简单设计及其实际优势。这里概述的原理适用于深度学习模型中的任何密集层，尽管在我们的实验中，我们仅关注Transformer语言模型中的某些权重作为激励用例。

4.1 低秩参数化更新矩阵

神经网络包含许多执行矩阵乘法的密集层。这些层中的权重矩阵通常具有满秩。当适应特定任务时，Aghajanyan等人（2020）表明，预训练语言模型具有较低的“内在维度”，并且尽管随机投影到较小的子空间，仍能高效学习。受此启发，我们假设在适应过程中对权重的更新也具有较低的“内在秩”。对于预训练权重矩阵$W_0 \in \mathbb{R}^{d\times k}$，我们通过用低秩分解$W_0 + \Delta W = W_0 + BA$表示其更新来约束该更新，其中$B \in \mathbb{R}^{d\times r}, A \in \mathbb{R}^{r\times k}$，且秩$r \ll \min(d, k)$。在训练期间，$W_0$被冻结且不接收梯度更新，而$A$和$B$包含可训练参数。注意$W_0$和$\Delta W = BA$都与相同的输入相乘，并且它们各自的输出向量按坐标求和。对于$h = W_0x$，我们修改后的前向传播产生：

$$h = W_0x + \Delta Wx = W_0x + BAx \tag{3}$$

我们在图1中展示了我们的重参数化。我们对A使用随机高斯初始化，对B使用零初始化，因此在训练开始时$\Delta W = BA$为零。然后我们将ΔWx按$\frac{\alpha}{r}$缩放，其中α是r中的一个常数。当使用Adam进行优化时，如果我们适当地缩放初始化，调整α大致等同于调整学习率。因此，我们只需将α设置为我们尝试的第一个r，而不对其进行调优。这种缩放有助于减少当我们改变r (Yang & Hu, 2021)时重新调优超参数的需求。

完全微调的泛化。一种更通用的微调形式允许训练预训练参数的一个子集。LoRA更进一步，不要求权重矩阵的累积梯度更新在适应过程中具有满秩。这意味着，当将LoRA应用于所有权重矩阵并训练所有偏置[2]时，通过将LoRA秩r设置为预训练权重矩阵的秩，我们大致恢复了完全微调的表达能力。换句话说，随着我们增加可训练参数的数量[3]，训练LoRA大致收敛于训练原始模型，而基于适配器的方法收敛于一个MLP，基于前缀的方法收敛于一个无法接受长输入序列的模型。

无额外推理延迟。当部署到生产环境时，我们可以显式计算并存储$W = W_0 + BA$，并照常进行推理。注意W_0和BA都在$\mathbb{R}^{d\times k}$中。当我们需要切换到另一个下游任务时，我们可以通过减去BA然后加上一个不同的$B'A'$来恢复W_0，这是一种快速操作，内存开销非常小。关键是，这

[2] They represent a negligible number of parameters compared to weights.

[3] An inevitability when adapting to hard tasks.

保证我们通过构造在推理过程中不会引入任何额外的延迟，与微调模型相比。

4.2 将LoRA应用于Transformer

原则上，我们可以将LoRA应用于神经网络中任意子集的权重矩阵，以减少可训练参数的数量。在Transformer架构中，自注意力模块中有四个权重矩阵（W_q, W_k, W_v, W_o），MLP模块中有两个。我们将W_q (或W_k、W_v)视为维度为$d_{model} \times d_{model}$的单个矩阵，即使输出维度通常被切分为多个注意力头。为了简单性和参数效率，我们将研究限制为仅针对下游任务调整注意力权重，并冻结MLP模块（因此它们在下游任务中不被训练）。我们在第7.1节进一步研究了在Transformer中适应不同类型注意力权重矩阵的效果。我们将对适应MLP层、LayerNorm层和偏置的经验性研究留待未来工作。

实际收益与局限性。最显著的收益来自内存和存储使用的减少。对于使用Adam训练的大型Transformer，我们将VRAM使用量减少最多2/3，如果$r \ll d_{model}$，因为我们不需要为冻结参数存储优化器状态。在GPT-3 175B上，我们将训练期间的VRAM消耗从1.2TB减少到350 GB。使用$r = 4$且仅适配查询和值投影矩阵时，检查点大小大约减少10,000× (，从350GB减少到35MB)[4]。这使我们能够用显著更少的GPU进行训练，并避免I/O瓶颈。另一个收益是，我们可以在部署时以低得多的成本在任务之间切换，只需交换LoRA权重而不是所有参数。这允许创建许多定制模型，这些模型可以在将预训练权重存储在VRAM中的机器上即时换入换出。我们还观察到，与完全微调[5]相比，在GPT-3 175B上训练期间实现了25%的加速，因为我们不需要为绝大多数参数计算梯度。

LoRA 也有其局限性。例如，如果选择将 A 和 B 吸收到 W 中以消除额外的推理延迟，那么在一次前向传播中，将具有不同 A 和 B 的不同任务的输入进行批处理并不直接。尽管在延迟不关键的场景下，可以不合并权重并动态选择批次中样本要使用的 LoRA 模块。

5 实证实验

我们在RoBERTa（Liu等人，2019）、DeBERTa（He等人，2021）和GPT-2（Radford等人，b）上评估LoRA的下游任务性能，然后扩展到GPT-3 175B（Brown等人，2020）。我们的实验涵盖了从自然语言理解（NLU）到生成（NLG）的广泛任务。具体而言，我们在RoBERTa和DeBERTa上评估GLUE（Wang等人，2019）基准。我们在GPT-2上遵循Li & Liang（2021）的设置以进行直接比较，并为GPT-3的大规模实验添加了WikiSQL（Zhong等人，2017）（自然语言到SQL查询）和SAMSum（Gliwa等人，2019）（对话摘要）。关于我们所使用数据集的更多细节，请参见附录C。所有实验均使用NVIDIA Tesla V100。

5.1 基线

为了与其他基线进行广泛比较，我们复现了先前工作所使用的设置，并在可能的情况下复用其报告的数字。然而，这意味着某些基线可能仅出现在特定实验中。

微调（FT）是一种常见的适应方法。在微调过程中，模型被初始化为预训练的权重和偏置，所有模型参数都进行梯度更新。一个简单的变体是仅更新部分层而冻结其他层。我们纳入了先前工作（Li & Liang, 2021）中在GPT-2上报告的一个此类基线，该基线仅调整最后两层（FT^{Top2}）。

[4]We still need the 350GB model during deployment; however, storing 100 adapted models only requires 350GB + 35MB * 100 ≈ 354GB as opposed to 100 * 350GB ≈ 35TB.

[5]For GPT-3 175B, the training throughput for full fine-tuning is 32.5 tokens/s per V100 GPU; with the same number of weight shards for model parallelism, the throughput is 43.1 tokens/s per V100 GPU for LoRA.

Model & Method	# Trainable Parameters	MNLI	SST-2	MRPC	CoLA	QNLI	QQP	RTE	STS-B	Avg.
RoB_{base} (FT)*	125.0M	**87.6**	94.8	90.2	**63.6**	92.8	**91.9**	78.7	91.2	86.4
RoB_{base} (BitFit)*	0.1M	84.7	93.7	**92.7**	62.0	91.8	84.0	81.5	90.8	85.2
RoB_{base} (Adpt^{D})*	0.3M	$87.1_{\pm.0}$	$94.2_{\pm.1}$	$88.5_{\pm1.1}$	$60.8_{\pm.4}$	$93.1_{\pm.1}$	$90.2_{\pm.0}$	$71.5_{\pm2.7}$	$89.7_{\pm.3}$	84.4
RoB_{base} (Adpt^{D})*	0.9M	$87.3_{\pm.1}$	$94.7_{\pm.3}$	$88.4_{\pm.1}$	$62.6_{\pm.9}$	$93.0_{\pm.2}$	$90.6_{\pm.0}$	$75.9_{\pm2.2}$	$90.3_{\pm.1}$	85.4
RoB_{base} (LoRA)	0.3M	$87.5_{\pm.3}$	$\mathbf{95.1}_{\pm.2}$	$89.7_{\pm.7}$	$63.4_{\pm1.2}$	$\mathbf{93.3}_{\pm.3}$	$90.8_{\pm.1}$	$\mathbf{86.6}_{\pm.7}$	$\mathbf{91.5}_{\pm.2}$	**87.2**
$\text{RoB}_{\text{large}}$ (FT)*	355.0M	90.2	**96.4**	**90.9**	68.0	94.7	**92.2**	86.6	92.4	88.9
$\text{RoB}_{\text{large}}$ (LoRA)	0.8M	$\mathbf{90.6}_{\pm.2}$	$96.2_{\pm.5}$	$\mathbf{90.9}_{\pm1.2}$	$\mathbf{68.2}_{\pm1.9}$	$\mathbf{94.9}_{\pm.3}$	$91.6_{\pm.1}$	$\mathbf{87.4}_{\pm2.5}$	$\mathbf{92.6}_{\pm.2}$	**89.0**
$\text{RoB}_{\text{large}}$ (Adpt^{P})†	3.0M	$90.2_{\pm.3}$	$96.1_{\pm.3}$	$90.2_{\pm.7}$	$\mathbf{68.3}_{\pm1.0}$	$\mathbf{94.8}_{\pm.2}$	$\mathbf{91.9}_{\pm.1}$	$83.8_{\pm2.9}$	$92.1_{\pm.7}$	88.4
$\text{RoB}_{\text{large}}$ (Adpt^{P})†	0.8M	$\mathbf{90.5}_{\pm.3}$	$\mathbf{96.6}_{\pm.2}$	$89.7_{\pm1.2}$	$67.8_{\pm2.5}$	$\mathbf{94.8}_{\pm.3}$	$91.7_{\pm.2}$	$80.1_{\pm2.9}$	$91.9_{\pm.4}$	87.9
$\text{RoB}_{\text{large}}$ (Adpt^{H})†	6.0M	$89.9_{\pm.5}$	$96.2_{\pm.3}$	$88.7_{\pm2.9}$	$66.5_{\pm4.4}$	$94.7_{\pm.2}$	$92.1_{\pm.1}$	$83.4_{\pm1.1}$	$91.0_{\pm1.7}$	87.8
$\text{RoB}_{\text{large}}$ (Adpt^{H})†	0.8M	$90.3_{\pm.3}$	$96.3_{\pm.5}$	$87.7_{\pm1.7}$	$66.3_{\pm2.0}$	$94.7_{\pm.2}$	$91.5_{\pm.1}$	$72.9_{\pm2.9}$	$91.5_{\pm.5}$	86.4
$\text{RoB}_{\text{large}}$ (LoRA)†	0.8M	$\mathbf{90.6}_{\pm.2}$	$96.2_{\pm.5}$	$\mathbf{90.2}_{\pm1.0}$	$68.2_{\pm1.9}$	$\mathbf{94.8}_{\pm.3}$	$91.6_{\pm.2}$	$\mathbf{85.2}_{\pm1.1}$	$\mathbf{92.3}_{\pm.5}$	**88.6**
DeB_{XXL} (FT)*	1500.0M	91.8	**97.2**	92.0	72.0	**96.0**	92.7	93.9	92.9	91.1
DeB_{XXL} (LoRA)	4.7M	$\mathbf{91.9}_{\pm.2}$	$96.9_{\pm.2}$	$\mathbf{92.6}_{\pm.6}$	$\mathbf{72.4}_{\pm1.1}$	$\mathbf{96.0}_{\pm.1}$	$\mathbf{92.9}_{\pm.1}$	$\mathbf{94.9}_{\pm.4}$	$\mathbf{93.0}_{\pm.2}$	**91.3**

表2：在GLUE基准上采用不同适配方法的$\text{RoBERTa}_{\text{base}}$、$\text{RoBERTa}_{\text{large}}$和$\text{DeBERTa}_{\text{XXL}}$。我们报告MNLI的整体（匹配和不匹配）准确率、CoLA的Matthew相关系数、STS-B的Pearson相关系数以及其他任务的准确率。所有指标均为越高越好。*表示先前工作中已发表的数字。†表示在与Houlsby等人（2019）相似的设置中配置的运行，以便进行公平比较。

仅偏置或BitFit是一种基线方法，其中我们仅训练偏置向量，同时冻结其他所有部分。同时，这一基线方法也已被BitFit（Zaken等，2021）研究。

前缀嵌入调优（PreEmbed）在输入词元中插入特殊词元。这些特殊词元具有可训练的詞嵌入，并且通常不在模型的词汇表中。放置这些词元的位置可能会影响性能。我们关注“前缀化”，即将此类词元前置到提示中，以及“中缀化”，即将其附加到提示中；两者均在Li & Liang (2021) 中讨论。我们用 l_p (分别表示前缀（相应地，中缀）词元的数量。可训练参数的数量为 $|\Theta| = d_{model} \times (l_p + l_i)$。

前缀层调优（PreLayer）是前缀嵌入调优的一种扩展。我们不仅学习某些特殊词的词嵌入（或等价地，嵌入层之后的激活值），还学习每个Transformer层之后的激活值。由前几层计算得到的激活值被简单地替换为可训练的激活值。由此产生的可训练参数数量为 $|\Theta| = L \times d_{model} \times (l_p + l_i)$，其中$L$是Transformer层的数量。

Houlsby等人（2019）提出的适配器调优在自注意力模块（以及MLP模块）与随后的残差连接之间插入适配器层。适配器层中有两个带偏置的全连接层，中间有一个非线性激活函数。我们将这种原始设计称为$\text{Adapter}^{\text{H}}$。最近，Lin等人（2020）提出了一种更高效的设计，仅在MLP模块之后和LayerNorm之后应用适配器层。我们称之为$\text{Adapter}^{\text{L}}$。这与Pfeiffer等人（2021）提出的另一种设计非常相似，我们称之为$\text{Adapter}^{\text{P}}$。我们还加入了另一个基线，称为AdapterDrop（Rücklé等人，2020），它丢弃一些适配器层以获得更高的效率（$\text{Adapter}^{\text{D}}$）。我们尽可能引用先前工作中的数字，以最大化我们比较的基线数量；它们位于第一列带有星号（*）的行中。在所有情况下，我们有$|\Theta| = \hat{L}_{Adpt} \times (2 \times d_{model} \times r + r + d_{model}) + 2 \times \hat{L}_{LN} \times d_{model}$，其中$\hat{L}_{Adpt}$是适配器层的数量，$\hat{L}_{LN}$是可训练LayerNorm的数量（例如，在$\text{Adapter}^{\text{L}}$中）。

LoRA将可训练的一对秩分解矩阵并行添加到现有权重矩阵中。如第4.2节所述，为简单起见，在大多数实验中我们仅对W_q和W_v应用LoRA。可训练参数的数量由秩r和原始权重的形状决定：$|\Theta| = 2 \times \hat{L}_{LoRA} \times d_{model} \times r$，其中$\hat{L}_{LoRA}$是我们应用LoRA的权重矩阵数量。

Model & Method	# Trainable Parameters	E2E NLG Challenge				
		BLEU	NIST	MET	ROUGE-L	CIDEr
GPT-2 M (FT)*	354.92M	68.2	8.62	46.2	71.0	2.47
GPT-2 M ($\text{Adapter}^{\text{L}}$)*	0.37M	66.3	8.41	45.0	69.8	2.40
GPT-2 M ($\text{Adapter}^{\text{L}}$)*	11.09M	68.9	8.71	46.1	71.3	2.47
GPT-2 M ($\text{Adapter}^{\text{H}}$)	11.09M	$67.3_{\pm.6}$	$8.50_{\pm.07}$	$46.0_{\pm.2}$	$70.7_{\pm.2}$	$2.44_{\pm.01}$
GPT-2 M (FT^{Top2})*	25.19M	68.1	8.59	46.0	70.8	2.41
GPT-2 M (PreLayer)*	0.35M	69.7	8.81	46.1	71.4	2.49
GPT-2 M (LoRA)	0.35M	$\mathbf{70.4}_{\pm.1}$	$\mathbf{8.85}_{\pm.02}$	$\mathbf{46.8}_{\pm.2}$	$\mathbf{71.8}_{\pm.1}$	$\mathbf{2.53}_{\pm.02}$
GPT-2 L (FT)*	774.03M	68.5	8.78	46.0	69.9	2.45
GPT-2 L ($\text{Adapter}^{\text{L}}$)	0.88M	$69.1_{\pm.1}$	$8.68_{\pm.03}$	$46.3_{\pm.0}$	$71.4_{\pm.2}$	$\mathbf{2.49}_{\pm.0}$
GPT-2 L ($\text{Adapter}^{\text{L}}$)	23.00M	$68.9_{\pm.3}$	$8.70_{\pm.04}$	$46.1_{\pm.1}$	$71.3_{\pm.2}$	$2.45_{\pm.02}$
GPT-2 L (PreLayer)*	0.77M	70.3	8.85	46.2	71.7	2.47
GPT-2 L (LoRA)	0.77M	$\mathbf{70.4}_{\pm.1}$	$\mathbf{8.89}_{\pm.02}$	$\mathbf{46.8}_{\pm.2}$	$\mathbf{72.0}_{\pm.2}$	$2.47_{\pm.02}$

表3：GPT-2中型（M）和大型（L）模型在E2E NLG挑战赛上采用不同适应方法的表现。对于所有指标，数值越高越好。LoRA在可训练参数相当或更少的情况下，优于多个基线。我们进行的实验展示了置信区间。*表示先前工作中发布的数字。

5.2 ROBERTA BASE/LARGE

RoBERTa（Liu 等，2019）优化了最初在 BERT（Devlin 等，2019a）中提出的预训练方案，并在不引入大量额外可训练参数的情况下提升了下游任务性能。尽管近年来 RoBERTa 在 GLUE 基准（Wang 等，2019）等 NLP 排行榜上已被规模大得多的模型超越，但就其参数量而言，它仍然是实践者眼中具有竞争力且受欢迎的预训练模型。我们从 HuggingFace Transformers 库（Wolf 等，2020）中取预训练的 RoBERTa base（125M）和 RoBERTa large（355M），并在 GLUE 基准任务上评估不同高效适配方法的性能。我们还按照 Houlsby 等（2019）和 Pfeiffer 等（2021）的设置复现了他们的方法。为确保公平比较，我们在将 LoRA 与 adapter 比较时做了两个关键调整。第一，我们对所有任务使用相同的 batch size，并使用 128 的序列长度以匹配 adapter 基线。第二，对于 MRPC、RTE 和 STS-B，我们将模型初始化为预训练模型，而不是像微调基线那样初始化为已适配 MNLI 的模型。遵循 Houlsby 等（2019）这一更严格设置的运行结果标记为 †。结果见表 2（前三部分）。所用超参数的详细信息见 D.1 节。

5.3 DEBERTA XXL

DeBERTa（He等人，2021）是BERT的一个较新变体，其训练规模更大，在GLUE（Wang等人，2019）和SuperGLUE（Wang等人，2020）等基准测试上表现极具竞争力。我们评估了LoRA是否仍能在GLUE上匹配完全微调的DeBERTa XXL（1.5B）的性能。结果见表2（底部部分）。所用超参数的详细信息见D.2节。

5.4 GPT-2 中型/大型

在证明了LoRA可以作为NLU全微调的有竞争力的替代方案后，我们希望回答LoRA在NLG模型上是否仍然占优势，例如GPT-2 medium和large（Radford等人，b）。我们尽可能保持设置与Li & Liang（2021）接近，以便进行直接比较。由于篇幅限制，本节仅展示我们在E2E NLG Challenge上的结果（表3）。关于WebNLG（Gardent等人，2017）和DART（Nan等人，2020）的结果见F.1节。我们在D.3节中列出了所使用的超参数列表。

Model&Method	# Trainable Parameters	WikiSQL Acc. (%)	MNLI-m Acc. (%)	SAMSum R1/R2/RL
GPT-3 (FT)	175,255.8M	**73.8**	89.5	52.0/28.0/44.5
GPT-3 (BitFit)	14.2M	71.3	91.0	51.3/27.4/43.5
GPT-3 (PreEmbed)	3.2M	63.1	88.6	48.3/24.2/40.5
GPT-3 (PreLayer)	20.2M	70.1	89.5	50.8/27.3/43.5
GPT-3 ($\text{Adapter}^{\text{H}}$)	7.1M	71.9	89.8	53.0/28.9/44.8
GPT-3 ($\text{Adapter}^{\text{H}}$)	40.1M	73.2	**91.5**	53.2/29.0/45.1
GPT-3 (LoRA)	4.7M	73.4	**91.7**	**53.8/29.8/45.9**
GPT-3 (LoRA)	37.7M	**74.0**	**91.6**	53.4/29.2/45.1

表4：不同适应方法在GPT-3 175B上的性能。我们报告了在WikiSQL上的逻辑形式验证准确率、在MultiNLI匹配集上的验证准确率，以及在SAMSum上的Rouge-1/2/L。LoRA的表现优于先前的方法，包括全量微调。WikiSQL上的结果有约±0.5%的波动，MNLI-m约有±0.1%的波动，而SAMSum在三个指标上分别约有±0.2/±0.2/±0.1的波动。

5.5 扩展到 GPT-3 175B

作为LoRA的最终压力测试，我们扩展到具有1750亿参数的GPT-3。由于训练成本高昂，我们仅报告给定任务在随机种子上的典型标准差，而不是为每个条目提供标准差。有关所用超参数的详细信息，请参见第D.4节。

如表4所示，LoRA在所有三个数据集上均达到或超过了微调基线。请注意，并非所有方法都能从更多可训练参数中单调受益，如图2所示。我们观察到，当为前缀嵌入调优使用超过256个特殊标记，或为前缀层调优使用超过32个特殊标记时，性能显著下降。这与Li & Liang（2021）中的类似观察结果相印证。虽然对这一现象的彻底调查超出了本工作的范围，但我们怀疑拥有更多特殊标记会导致输入分布进一步偏离预训练数据分布。另外，我们在F.3节中研究了不同适应方法在低数据情形下的性能。

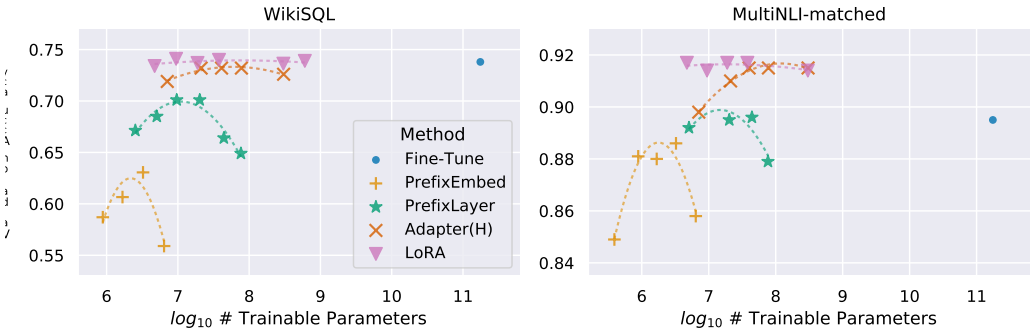


图2：GPT-3 175B在WikiSQL和MNLI匹配任务上，不同适应方法的验证准确率与可训练参数数量的关系。LoRA展现出更好的可扩展性和任务性能。有关绘制数据点的更多细节，请参见F.2节。

6 相关工作

Transformer语言模型。Transformer（Vaswani等，2017）是一种大量使用自注意力机制的序列到序列架构。Radford等（a）通过使用Transformer解码器堆栈将其应用于自回归语言建模。此后，基于Transformer的语言模型在NLP领域占据主导地位，在许多任务中达到了最先进的水平。随着BERT（Devlin等，2019b）和GPT-2（Radford等，b）的出现，一种新的范式出现了——两者都是大型Transformer语言

在大量文本上训练的语言模型——其中，在通用领域数据上进行预训练后，再针对特定任务数据进行微调，与直接在特定任务数据上训练相比，能带来显著的性能提升。训练更大的Transformer通常会产生更好的性能，并且仍然是一个活跃的研究方向。GPT-3（Brown等，2020）是迄今为止训练过的最大单一Transformer语言模型，拥有1750亿参数。

提示工程与微调。尽管GPT-3 175B仅需少量额外训练样本即可调整其行为，但结果在很大程度上取决于输入提示（Brown等，2020）。这要求一种经验性的艺术，即编写和格式化提示以最大化模型在期望任务上的性能，这被称为提示工程或提示黑客。微调是将预训练于通用领域的模型重新训练以适应特定任务（Devlin等，2019b；Radford等，a）。其变体包括仅学习参数的一个子集（Devlin等，2019b；Collobert & Weston，2008），然而从业者通常重新训练所有参数以最大化下游性能。然而，GPT-3 175B的庞大规模使得以常规方式进行微调具有挑战性，因为它产生的检查点巨大，且进入的硬件门槛很高，因为它具有与预训练相同的内存占用。

参数高效自适应。许多人提出在神经网络中现有层之间插入*adapter*层（Houlsby等，2019；Rebuffi等，2017；Lin等，2020）。我们的方法采用类似的瓶颈结构，对权重更新施加低秩约束。关键的功能差异在于，我们学习到的权重在推理时可以与主权重合并，因此不会引入任何延迟，而适配器层则并非如此（第3节）。适配器的一个同期扩展是COMPACTER（Mahabadi等，2021），它本质上使用Kronecker积以及某种预定的权重共享方案来参数化适配器层。类似地，将LoRA与其他基于张量积的方法结合，可能潜在地提高其参数效率，我们将其留待未来工作。更近期地，许多人提出优化输入词嵌入而非微调，类似于提示工程的连续且可微的泛化（Li & Liang，2021；Lester等，2021；Hambardzumyan等，2020；Liu等，2021）。我们在实验部分包含了与Li & Liang（2021）的比较。然而，这一系列工作只能通过使用更多特殊标记来扩展，而当位置嵌入被学习时，这些特殊标记会占用任务标记可用的序列长度。

深度学习中的低秩结构。低秩结构在机器学习中非常常见。许多机器学习问题都具有某种内在的低秩结构（Li et al., 2016; Cai et al., 2010; Li et al., 2018b; Grasedyck et al., 2013）。此外，众所周知，对于许多深度学习任务，尤其是那些使用严重过参数化神经网络的任务，学习到的神经网络在训练后将具有低秩特性（Oymak et al., 2019）。一些先前的工作甚至在训练原始神经网络时显式地施加低秩约束（Sainath et al., 2013; Povey et al., 2018; Zhang et al., 2014; Jaderberg et al., 2014; Zhao et al., 2016; Khodak et al., 2021; Denil et al., 2014）；然而，据我们所知，这些工作中没有一个考虑对冻结模型进行低秩更新以用于*adaptation to downstream tasks*。在理论文献中，已知当底层概念类具有某种低秩结构时，神经网络优于其他经典学习方法，包括相应的（有限宽度）神经正切核（Allen-Zhu et al., 2019; Li & Liang, 2018）（Ghorbani et al., 2020; Allen-Zhu & Li, 2019; Allen-Zhu & Li, 2020a）。Allen-Zhu & Li (2020b) 的另一项理论结果表明，低秩自适应可用于对抗训练。总之，我们认为我们提出的低秩自适应更新在文献中有充分的动机。

7 理解低秩更新

鉴于LoRA的经验优势，我们希望进一步解释从下游任务中学到的低秩适应特性。值得注意的是，低秩结构不仅降低了硬件入门门槛，使我们能够并行运行多个实验，而且对于更新权重如何与预训练权重相关联提供了更好的可解释性。我们的研究集中在GPT-3 175B上，在此我们实现了可训练参数的最大缩减（高达10,000×），而未对任务性能产生不利影响。

我们进行了一系列实证研究来回答以下问题：1）在给定参数预算约束的情况下，预训练Transformer中的*which subset of weight matrices*我们应该调整吗

为了最大化下游性能？2）“最优”适应矩阵ΔW *really rank-deficient*吗？如果是，实践中应使用什么好的秩？3）ΔW与W之间的联系是什么？ΔW与W高度相关吗？ΔW与W相比有多大？

我们认为，我们对问题（2）和（3）的回答揭示了使用预训练语言模型进行下游任务的基本原则，这是NLP中的一个关键主题。

7.1 在Transformer中，我们应该对哪些权重矩阵应用LoRA？

在有限的参数预算下，我们应该用LoRA适应哪些类型的权重才能在下游任务上获得最佳性能？如第4.2节所述，我们仅考虑自注意力模块中的权重矩阵。我们在GPT-3 175B上设定了18M的参数预算（若以FP16存储则约为35MB），对于所有96层，这相当于如果我们适应一种注意力权重则为$r = 8$，如果我们适应两种则为$r = 4$。结果呈现在表5中。

	# of Trainable Parameters = 18M						
Weight Type	W_q	W_k	W_v	W_o	W_q, W_k	W_q, W_v	W_q, W_k, W_v, W_o
Rank r	8	8	8	8	4	4	2
WikiSQL ($\pm 0.5\%$)	70.4	70.0	73.0	73.2	71.4	**73.7**	**73.7**
MultiNLI ($\pm 0.1\%$)	91.0	90.8	91.0	91.3	91.3	91.3	**91.7**

表5：在GPT-3中，对不同类型的注意力权重应用LoRA后，在WikiSQL和MultiNLI上的验证准确率，给定相同数量的可训练参数。同时适配W_q和W_v总体上给出了最佳性能。我们发现，对于给定的数据集，随机种子间的标准差是一致的，我们在第一列中报告了这一结果。

请注意，将所有参数放入 ΔW_q 或 ΔW_k 会导致性能显著降低，而同时适配 W_q 和 W_v 则能获得最佳结果。这表明，即使是秩为四的 ΔW 也能捕获足够的信息，因此相比于以更大的秩适配单一类型的权重，适配更多的权重矩阵更为可取。

7.2 对于LoRA，最优秩r是什么？

我们将注意力转向秩 r 对模型性能的影响。我们调整 $\{W_q, W_v\}$、$\{W_q, W_k, W_v, W_c\}$ 以及仅 W_q 以进行比较。

	Weight Type	$r = 1$	$r = 2$	$r = 4$	$r = 8$	$r = 64$
WikiSQL($\pm 0.5\%$)	W_q	68.8	69.6	70.5	70.4	70.0
	W_q, W_v	73.4	73.3	73.7	73.8	73.5
	W_q, W_k, W_v, W_o	74.1	73.7	74.0	74.0	73.9
MultiNLI ($\pm 0.1\%$)	W_q	90.7	90.9	91.1	90.7	90.7
	W_q, W_v	91.3	91.4	91.3	91.6	91.4
	W_q, W_k, W_v, W_o	91.2	91.7	91.7	91.5	91.4

表6：在WikiSQL和MultiNLI上使用不同秩r的验证准确率。令我们惊讶的是，在这些数据集上，秩小至1就足以适配W_q和W_v，而单独训练W_q则需要更大的r。我们在H.2节中对GPT-2进行了类似的实验。

表6显示，令人惊讶的是，LoRA在极小的r (下已经具有竞争力，对于$\{W_q, W_v\}$而言更是如此，而不仅仅是W_q)。这表明更新矩阵ΔW可能具有非常小的“内在秩”。[6]为了进一步支持这一发现，我们检查了由不同r选择和不同随机种子所学到的子空间的重叠情况。我们认为增加r并不会覆盖更有意义的子空间，这表明低秩适应矩阵已经足够。

然而，我们并不期望一个小的 r 能在每个任务或数据集上都奏效。考虑以下思想实验：如果下游任务使用的语言与预训练时使用的语言不同，那么重新训练整个模型（类似于使用 $r = d_{model}$ 的 LoRA）肯定会优于使用小 r 的 LoRA。

不同 $\boldsymbol{r}$ 之间的子空间相似性。给定 $A_{r=8}$ 和 $A_{r=64}$，它们分别是使用 *same pre-trained model* 学习到的秩为 $r = 8$ 和 64 的适应矩阵，我们进行奇异值分解，得到右奇异酉矩阵 $U_{A_{r=8}}$ 和 $U_{A_{r=64}}$。[7] 我们希望回答：对于 $1 \leq i \leq 8$)，$U_{A_{r=8}}$ (中前 i 个奇异向量所张成的子空间，有多少包含在对于 $1 \leq j \leq 64$) 的 $U_{A_{r=64}}$ (的前 j 个奇异向量所张成的子空间中？我们使用基于格拉斯曼距离的归一化子空间相似性来度量这一量（更正式的讨论见附录 G）

$$\phi(A_{r=8}, A_{r=64}, i, j) = \frac{||U^{i\top}_{A_{r=8}} U^{j}_{A_{r=64}}||^2_F}{\min(i, j)} \in [0, 1] \tag{4}$$

其中 $U^{i}_{A_{r=8}}$ 表示 $U_{A_{r=8}}$ 中对应于前 i 个奇异向量的列。

$\phi(\cdot)$ 其取值范围为[0, 1]，其中1表示子空间完全重叠，0表示完全分离。关于ϕ如何随i和j的变化而变化，请参见图3。由于篇幅限制，我们仅考察第48层（共96层），但该结论同样适用于其他层，如H.1节所示。

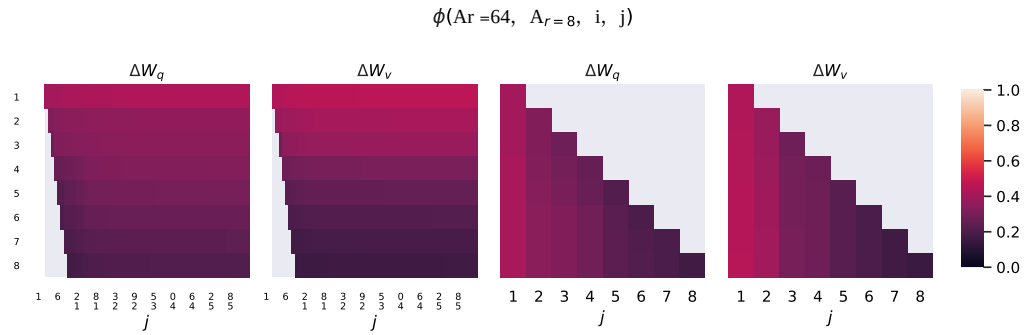


图3：$A_{r=8}$和$A_{r=64}$的列向量在ΔW_q和ΔW_v两种情况下的子空间相似性。第三幅和第四幅图放大了前两幅图中左下角三角形的区域。$r = 8$中的顶部方向包含在$r = 64$中，反之亦然。

我们由图3制作一个*important observation*。

> 与顶部奇异向量对应的方向在$A_{r=8}$和$A_{r=64}$之间显著重叠，而其他方向则不然。具体而言，$A_{r=8}$的ΔW_v (（分别地，ΔW_q)）与$A_{r=64}$的ΔW_v (（分别地，ΔW_q)）共享一个维度为1的子空间，归一化相似度为> 0.5，这解释了为什么$r = 1$在GPT-3的下游任务中表现相当好。

由于 $A_{r=8}$ 和 $A_{r=64}$ 都是使用相同的预训练模型学习得到的，图 3 表明 $A_{r=8}$ 和 $A_{r=64}$ 的顶部奇异向量方向最为有用，而其他方向可能主要包含训练过程中累积的随机噪声。因此，适应矩阵确实可以具有非常低的秩。

不同随机种子之间的子空间相似性。我们通过绘制两次随机种子运行（$r = 64$）之间的归一化子空间相似性进一步确认了这一点，如图4所示。ΔW_q 似乎比 ΔW_v 具有更高的“内在秩”，因为两次运行都为 ΔW_q 学习到了更多共同的奇异值方向，这与我们在表6中的经验观察一致。作为对比，我们还绘制了两个随机高斯矩阵，它们彼此之间不共享任何共同的奇异值方向。

7.3 适应矩阵 ΔW 与 W 相比如何?

我们进一步研究 ΔW 与 W 之间的关系。特别地，ΔW 是否与 W 高度相关？（或者从数学上说，ΔW 是否主要包含在 W 的前几个奇异方向中？）此外，

[7] Note that a similar analysis can be carried out with B and the left-singular unitary matrices – we stick with A for our experiments.

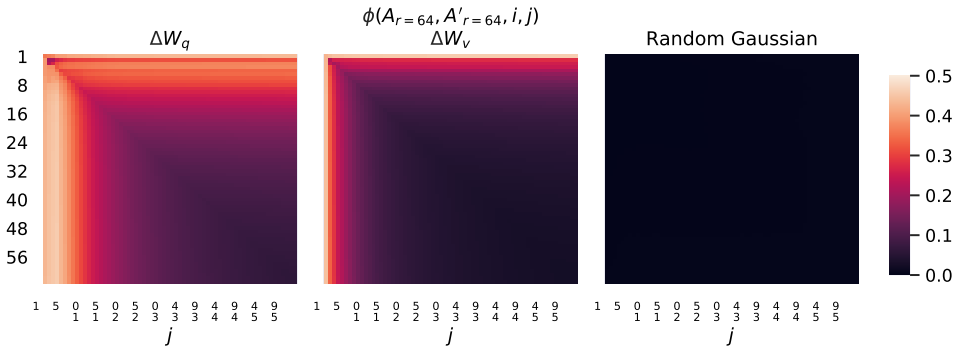


图4：左图和中图：在第48层中，对于ΔW_q和ΔW_v，来自两个随机种子的$A_{r=64}$的列向量之间的归一化子空间相似度。右图：两个随机高斯矩阵的列向量之间的相同热图。其他层见H.1节。

与 W 中对应的方向相比，ΔW 有多“大”？这可以揭示适应预训练语言模型的潜在机制。

为了回答这些问题，我们将 W 投影到 ΔW 的 r 维子空间上，通过计算 $U^\top W V^\top$，其中 U / V 是 ΔW 的左/右奇异向量矩阵。然后，我们比较 $\|U^\top W V^\top\|_F$ 和 $\|W\|_F$ 之间的 Frobenius 范数。作为对比，我们还通过将 U, V 替换为 W 的前 r 个奇异向量或随机矩阵来计算 $\|U^\top W V^\top\|_F$。

	$r=4$			$r=64$		
	ΔW_q	W_q	Random	ΔW_q	W_q	Random
$\|\|U^\top W_q V^\top\|\|_F =$	0.32	21.67	0.02	1.90	37.71	0.33
$\|\|W_q\|\|_F = 61.95$	$\|\|\Delta W_q\|\|_F = 6.91$			$\|\|\Delta W_q\|\|_F = 3.57$		

表7：$U^\top W_q V^\top$的Frobenius范数，其中U和V分别是（1）ΔW_q、（2）W_q或（3）随机矩阵的左/右前r个奇异向量方向。权重矩阵取自GPT-3的第48层。

我们从表7中提取*several conclusions*。首先，与随机矩阵相比，ΔW与W具有更强的相关性，这表明ΔW放大了W中已有的一些特征。其次，ΔW并非重复W的顶部奇异方向，而只是*amplifies directions that are not emphasized in* W。第三，放大因子相当大：对于$r = 4$，为21.5 $\approx 6.91/0.32$。关于为何$r = 64$具有较小的放大因子，请参见H.4节。我们还在H.3节中提供了可视化，展示了当我们从W_q中纳入更多顶部奇异方向时相关性如何变化。这表明低秩适应矩阵可能*amplifies the important features for specific downstream tasks that were learned but not emphasized in the general pre-training model*。

8 结论与未来工作

微调庞大的语言模型在所需硬件以及为不同任务托管独立实例的存储/切换成本方面极其昂贵。我们提出了LoRA，一种高效的适应策略，它既不引入推理延迟，也不减少输入序列长度，同时保持高模型质量。重要的是，当作为服务部署时，它通过共享绝大多数模型参数实现了快速的任务切换。虽然我们专注于Transformer语言模型，但所提出的原则普遍适用于任何具有密集层的神经网络。

未来工作有许多方向。1）LoRA可以与其他高效的适配方法结合，可能提供正交的改进。2）微调或LoRA背后的机制远未明确——预训练期间学到的特征如何被转换以在下游任务上表现良好？我们相信，LoRA使回答这个问题比完全微调更具可操作性。

调优。3) 我们主要依赖启发式方法来选择应用LoRA的权重矩阵。是否有更原则性的方法来进行选择？4) 最后，ΔW的秩亏性表明W也可能是秩亏的，这也可以为未来的工作提供灵感。

参考文献

Armen Aghajanyan, Luke Zettlemoyer, 和 Sonal Gupta. 内在维度解释了语言模型微调的有效性. *arXiv:2012.13255 [cs]*, 2020年12月. URL http://arxiv.org/abs/2012.13255. Zeyuan Allen-Zhu 和 Yuanzhi Li. ResNet能高效地学到什么，超越核方法？ In *NeurIPS*, 2019. 完整版本可在 http://arxiv.org/abs/1905.10337 获取. Zeyuan Allen-Zhu 和 Yuanzhi Li. 反向特征校正：深度学习如何执行深度学习. *arXiv preprint arXiv:2001.04413*, 2020a. Zeyuan Allen-Zhu 和 Yuanzhi Li. 特征纯化：对抗训练如何执行稳健的深度学习. *arXiv preprint arXiv:2005.10190*, 2020b. Zeyuan Allen-Zhu, Yuanzhi Li, 和 Zhao Song. 通过过参数化的深度学习收敛理论. In *ICML*, 2019. 完整版本可在 http://arxiv.org/abs/1811. 03962 获取. Jimmy Lei Ba, Jamie Ryan Kiros, 和 Geoffrey E. Hinton. 层归一化, 2016. Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhari- wal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever, 和 Dario Amodei. 语言模型是少样本学习器. *arXiv:2005.14165 [cs]*, 2020年7月. URL http://arxiv.org/abs/2005.14165. Jian-Feng Cai, Emmanuel J Candès, 和 Zuowei Shen. 矩阵补全的奇异值阈值算法. *SIAM Journal on optimization*, 20(4):1956–1982, 2010. Daniel Cer, Mona Diab, Eneko Agirre, Inigo Lopez-Gazpio, 和 Lucia Specia. Semeval-2017 任务 1：语义文本相似度多语言和跨语言聚焦评估. *Proceedings of the 11th International Workshop on Semantic Evaluation (SemEval-2017)*, 2017. doi: 10.18653/ v1/s17-2001. URL http://dx.doi.org/10.18653/v1/S17-2001. Ronan Collobert 和 Jason Weston. 自然语言处理的统一架构：具有多任务学习的深度神经网络. In *Proceedings of the 25th international conference on Machine learning*, ICML ’08, pp. 160–167, New York, NY, USA, July 2008. Association for Computing Machinery. ISBN 978-1-60558-205-4. doi: 10.1145/1390156.1390177. URL https://doi.org/10.1145/1390156.1390177. Misha Denil, Babak Shakibi, Laurent Dinh, Marc’Aurelio Ranzato, 和 Nando de Freitas. 深度学习中的参数预测, 2014. Jacob Devlin, Ming-Wei Chang, Kenton Lee, 和 Kristina Toutanova. Bert：用于语言理解的深度双向变换器预训练, 2019a. Jacob Devlin, Ming-Wei Chang, Kenton Lee, 和 Kristina Toutanova. BERT：用于语言理解的深度双向变换器预训练. *arXiv:1810.04805 [cs]*, May 2019b. URL http://arxiv.org/abs/1810.04805. arXiv: 1810.04805. William B. Dolan 和 Chris Brockett. 自动构建句子释义语料库. In *Proceedings of the Third International Workshop on Paraphrasing (IWP2005)*, 2005. URL https://aclanthology.org/I05-5002. Claire Gardent, Anastasia Shimorina, Shashi Narayan, 和 Laura Perez-Beltrachini. WebNLG挑战：从RDF数据生成文本. In *Proceedings of the 10th International Conference on Natural Language Generation*, pp. 124–133, 2017.

Behrooz Ghorbani, Song Mei, Theodor Misiakiewicz, 和 Andrea Montanari. 神经网络何时优于核方法？*arXiv preprint arXiv:2006.13409*, 2020.

博格丹·格利瓦、伊沃娜·莫霍尔、马切伊·别塞克和亚历山大·瓦维尔。Samsum语料库：一个用于抽象摘要的人工标注对话数据集。*CoRR*，abs/1911.12237，2019年。网址 http://arxiv.org/abs/1911.12237。

Lars Grasedyck、Daniel Kressner 和 Christine Tobler。低秩张量近似技术的文献综述。*GAMM-Mitteilungen*，36(1)：53–78，2013。

Jihun Ham 和 Daniel D. Lee。Grassmann 判别分析：基于子空间学习的统一视角。载于 *ICML*，第 376–383 页，2008 年。URL https://doi.org/10.1145/1390156. 1390204。

Karen Hambardzumyan、Hrant Khachatrian 和 Jonathan May。WARP：词级对抗性重编程。*arXiv:2101.00121 [cs]*，2020年12月。网址 http://arxiv.org/ 2101.00121。arXiv：2101.00121。

彭城何、刘晓东、高剑锋和陈伟柱。Deberta：具有解耦注意力的解码增强型BERT，2021。

尼尔·霍尔斯比、安德烈·久尔久、斯坦尼斯瓦夫·雅斯特热布斯基、布鲁娜·莫罗内、康坦·德·拉鲁西尔、安德烈亚·杰斯蒙多、莫娜·阿塔里扬和西尔万·热利。面向自然语言处理的参数高效迁移学习。*arXiv:1902.00751 [cs, stat]*，2019年6月。网址：http://arxiv.org/abs/1902.00751。

Max Jaderberg、Andrea Vedaldi 和 Andrew Zisserman。利用低秩展开加速卷积神经网络。*arXiv preprint arXiv:1405.3866*，2014。

米哈伊尔·霍达克、尼尔·特南霍尔茨、莱斯特·麦基和尼古拉奥·富西。因子化神经网络层的初始化与正则化，2021年。

迪德里克·P·金马和吉米·巴。Adam：一种随机优化方法，2017。

德米特里·列皮欣、李燏中、徐元中、陈德豪、奥尔罕·菲拉特、黄延平、马克西姆·克里昆、诺姆·沙泽尔和陳志峰。Gshard：通过条件计算和自动分片扩展巨型模型，2020年。

Brian Lester、Rami Al-Rfou和Noah Constant。参数高效提示调优的规模之力。*arXiv:2104.08691 [cs]*，2021年4月。网址http://arxiv.org/abs/2104.08691。arXiv：2104.08691。

Chunyuan Li, Heerad Farkhoor, Rosanne Liu, 和 Jason Yosinski. 测量目标景观的内在维度. *arXiv:1804.08838 [cs, stat]*, 2018年4月a. URL http://arxiv.org/abs/1804.08838. arXiv: 1804.08838.

项丽莎（Xiang Lisa Li）和珀西·梁（Percy Liang）。前缀调优：为生成优化连续提示。*arXiv:2101.00190 [cs]*，2021年1月。网址 http://arxiv.org/abs/2101.00190。

袁志李和梁英玉。在结构化数据上通过随机梯度下降学习过参数化神经网络。载于 *Advances in Neural Information Processing Systems*，2018年。

袁志利、梁英宇和 Andrej Risteski。通过交替最小化的加权低秩近似的恢复保证。载于 *International Conference on Machine Learning*，第 2358–2367 页。PMLR，2016 年。

袁志利、马腾宇和张洪洋。过参数化矩阵感知与二次激活神经网络中的算法正则化。载于 *Conference On Learning The- ory*，第2–47页。PMLR，2018b。

赵江林、Andrea Madotto 和 Pascale Fung。通过参数高效迁移学习探索多功能生成语言模型。载于 *Findings of the Association for Computational Lin- guistics: EMNLP 2020*，第 441–459 页，线上，2020 年 11 月。计算语言学协会。doi: 10.18653/v1/2020.findings-emnlp.41。网址 https://aclanthology.org/2020.findings-emnlp.41。

小刘、郑亚楠、杜正晓、丁明、钱玉洁、杨志林和唐杰。GPT也能理解。*arXiv:2103.10385 [cs]*，2021年3月。网址 http://arxiv.org/ 2103.10385。arXiv：2103.10385。

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, 和 Veselin Stoyanov. Roberta：一种稳健优化的bert预训练方法，2019。

伊利亚·洛希洛夫和弗兰克·胡特。解耦权重衰减正则化。*arXiv preprint arXiv:1711.05101*，2017年。

伊利亚·洛希洛夫和弗兰克·胡特。解耦权重衰减正则化，2019。

Rabeeh Karimi Mahabadi, James Henderson, 和 Sebastian Ruder. Compacter: 高效低秩超复数适配器层, 2021.

林永南、德拉戈米尔·拉德夫、张锐、阿姆里特·劳、阿比南德·西瓦普拉萨德、谢佳春、唐翔如、阿迪特·维亚斯、内哈·维尔马、普拉纳夫·克里希纳等。Dart：开放域结构化数据记录到文本生成。*arXiv preprint arXiv:2007.02871*，2020年。

Jekaterina Novikova, Ondřej Dušek, 和 Verena Rieser. e2e 数据集：端到端生成的新挑战。*arXiv preprint arXiv:1706.09254*, 2017. Samet Oymak, Zalan Fabian, Mingchen Li, 和 Mahdi Soltanolkotabi. 通过利用雅可比矩阵的低秩结构为神经网络提供泛化保证。*arXiv preprint arXiv:1906.05392*, 2019. Jonas Pfeiffer, Aishwarya Kamath, Andreas Rücklé, Kyunghyun Cho, 和 Iryna Gurevych. 适配器融合：用于迁移学习的非破坏性任务组合，2021. Daniel Povey, Gaofeng Cheng, Yiming Wang, Ke Li, Hainan Xu, Mahsa Yarmohammadi, 和 Sanjeev Khudanpur. 深度神经网络的半正交低秩矩阵分解。在 *Interspeech*, 第 3743–3747 页, 2018. Alec Radford, Karthik Narasimhan, Tim Salimans, 和 Ilya Sutskever. 通过生成式预训练提高语言理解。第 12 页, a. Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei, 和 Ilya Sutskever. 语言模型是无监督的多任务学习器。第 24 页, b. Pranav Rajpurkar, Robin Jia, 和 Percy Liang. 知道你所不知道的：SQuAD 的不可回答问题。*CoRR*, abs/1806.03822, 2018. URL http://arxiv.org/abs/1806.03822. Sylvestre-Alvise Rebuffi, Hakan Bilen, 和 Andrea Vedaldi. 使用残差适配器学习多个视觉域。*arXiv:1705.08045 [cs, stat]*, 2017年11月. URL http://arxiv.org/abs/1705.08045. arXiv: 1705.08045. Andreas Rücklé, Gregor Geigle, Max Glockner, Tilman Beck, Jonas Pfeiffer, Nils Reimers, 和 Iryna Gurevych. Adapterdrop：关于 Transformer 中适配器的效率，2020.

Tara N Sainath、Brian Kingsbury、Vikas Sindhwani、Ebru Arisoy和Bhuvana Ramabhadran。用于高维输出目标深度神经网络训练的低秩矩阵分解。载于*2013 IEEE international conference on acoustics, speech and signal processing*，第6655–6659页。IEEE，2013年。

穆罕默德·舒埃比、莫斯托法·帕特瓦里、劳尔·普里、帕特里克·勒格雷斯利、贾里德·卡斯珀和布莱恩·卡坦扎罗。Megatron-lm：使用模型并行训练数十亿参数的语言模型，2020年。

Richard Socher、Alex Perelygin、Jean Wu、Jason Chuang、Christopher D. Manning、Andrew Ng 和 Christopher Potts。用于情感树库语义组合性的递归深度模型。载于*Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing*，第 1631–1642 页，美国华盛顿州西雅图，2013 年 10 月。计算语言学协会。网址 https://aclanthology.org/D13-1170。

阿希什·瓦斯瓦尼、诺姆·沙泽尔、尼基·帕尔马、雅各布·乌兹科雷特、利昂·琼斯、艾丹·N·戈麦斯、 ukasz Kaiser 和 Illia Polosukhin。Attention is all you need。载于 *Proceedings of the 31st In- ternational Conference on Neural Information Processing Systems*，第 6000–6010 页，2017 年。

Alex Wang、Amanpreet Singh、Julian Michael、Felix Hill、Omer Levy 和 Samuel R. Bowman。Glue：自然语言理解的多任务基准与分析平台，2019。

Alex Wang, Yada Pruksachatkun, Nikita Nangia, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, 和 Samuel R. Bowman. Superglue: 一个更粘性的通用语言理解系统基准, 2020.

Alex Warstadt、Amanpreet Singh 和 Samuel R Bowman。神经网络可接受性判断。*arXiv preprint arXiv:1805.12471*，2018。

阿迪娜·威廉姆斯、尼基塔·南吉亚和塞缪尔·鲍曼。一个通过推理进行句子理解的广泛覆盖挑战语料库。载于*Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers)*，第1112–1122页，路易斯安那州新奥尔良，2018年6月。计算语言学协会。doi: 10.18653/v1/N18-1101。网址 https://www.aclweb.org/anthology/N18-1101。

托马斯·沃尔夫、利桑德尔·德布特、维克多·桑、朱利安·肖蒙、克莱门特·德朗格、安东尼·莫伊、皮埃里克·西斯塔克、蒂姆·劳尔特、Rémi Louf、摩根·丰托维奇、乔·戴维森、山姆·施莱弗、帕特里克·冯·普拉滕、克拉拉·马、亚辛·杰尼特、朱利安·普卢、徐灿文、特文·勒·斯卡奥、西尔万·古格、玛丽亚玛·德拉梅、昆汀·洛斯特和亚历山大·M·拉什。Transformers：最先进的自然语言处理。载于*Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*，第38–45页，在线，2020年10月。计算语言学协会。网址 https://www.aclweb.org/anthology/2020.emnlp-demos.6。

Greg Yang 和 Edward J. Hu。无限宽神经网络中的特征学习。*arXiv:2011.14522 [cond-mat]*，2021年5月。网址 http://arxiv.org/abs/2011.14522。arXiv：2011.14522。

埃拉德·本·扎肯、肖利·拉夫福格尔和约阿夫·戈德堡。Bitfit：面向基于Transformer的掩码语言模型的简单参数高效微调，2021。

张宇、Ekapol Chuangsuwanich 和 James Glass。使用低秩矩阵分解提取深度神经网络瓶颈特征。载于 *2014 IEEE international conference on acoustics, speech and signal processing (ICASSP)*，第185–189页。IEEE，2014年。

Yong Zhao、Jinyu Li 和 Yifan Gong。深度神经网络的低秩加对角自适应。载于 *2016 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*，第5005–5009 页。IEEE，2016。

Victor Zhong、Caiming Xiong和Richard Socher。Seq2sql：使用强化学习从自然语言生成结构化查询。*CoRR*，abs/1709.00103，2017。网址 http:// arxiv.org/abs/1709.00103。

大型语言模型仍然需要参数更新

少样本学习，或称提示工程，在我们仅有少量训练样本时非常有利。然而，在实践中，对于性能敏感的应用，我们通常能够精心整理数千个或更多的训练示例。如表8所示，与少样本学习相比，微调在大型和小型数据集上都能显著提升模型性能。我们从GPT-3论文（Brown等，2020）中采用了GPT-3在RTE上的少样本结果。对于MNLI匹配任务，我们为每个类别使用两个演示，总共使用六个上下文示例。

Method	MNLI-m (Val. Acc./%)	RTE (Val. Acc./%)
GPT-3 Few-Shot	40.6	69.0
GPT-3 Fine-Tuned	89.5	85.4

表8：微调在GPT-3上显著优于少样本学习（Brown等，2020）。

B 适配器层引入的推理延迟

适配器层是以*sequential*方式添加到预训练模型的外部模块，而我们的提案LoRA则可以被视为以并行方式添加的外部模块。因此，适配器层必须在基础模型之外进行计算，不可避免地引入了额外的延迟。然而，正如Rücklé等人（2020）所指出的，当模型批量大小和/或序列长度足够大以充分利用硬件并行性时，适配器层引入的延迟可以得到缓解。我们通过对GPT-2 medium进行类似的延迟研究证实了他们的观察，并指出在某些场景下，特别是在批量大小较小的在线推理中，增加的延迟可能非常显著。

我们在NVIDIA Quadro RTX8000上通过平均100次试验来测量单次前向传递的延迟。我们改变输入批次大小、序列长度以及适配器瓶颈维度r。我们测试了两种适配器设计：Houlsby等人（2019）提出的原始设计，我们称之为Adapter^{H}，以及Lin等人（2020）提出的一种近期更高效的变体，我们称之为Adapter^{L}。有关设计的更多细节，请参见第5.1节。我们在图5中绘制了与无适配器基线相比的减速百分比。

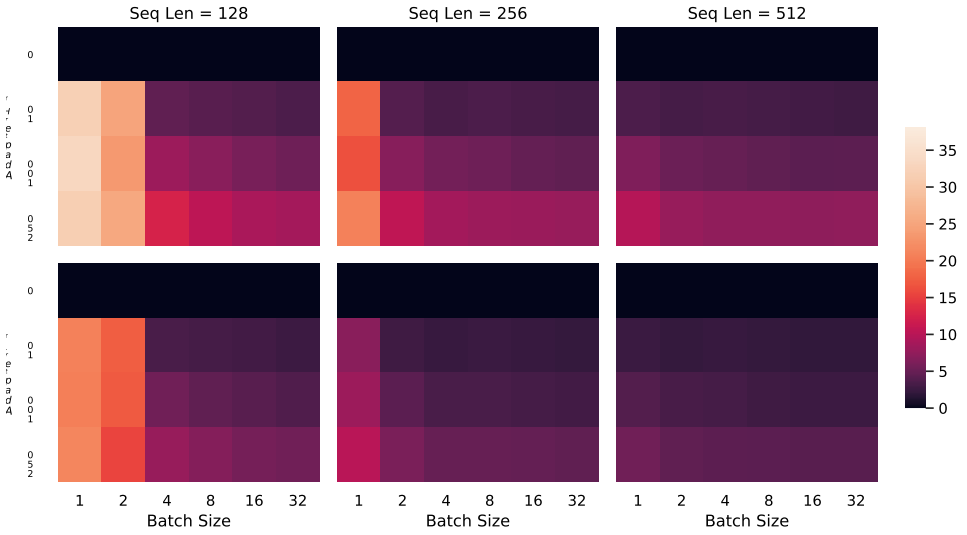


图5：与无适配器（$r = 0$）基线相比的推理延迟减慢百分比。上排显示Adapter^{H}的结果，下排显示Adapter^{L}的结果。更大的批大小和序列长度有助于缓解延迟，但在在线、短序列长度场景下，减慢幅度可高达30%以上。我们调整了颜色映射以提高可见性。

C 数据集详情

GLUE 基准是一个广泛的自然语言理解任务集合。它包括 MNLI（推理，Williams 等 (2018)）、SST-2（情感分析，Socher 等 (2013)）、MRPC（释义检测，Dolan & Brockett (2005)）、CoLA（语言可接受性，Warstadt 等 (2018)）、QNLI（推理，Rajpurkar 等 (2018)）、QQP[8] (问答)、RTE（推理），

[8] 小时 https://quoradata.quora.com/First-Quora-Dataset-Release-Question-Pairs

以及 STS-B（文本相似度，Cer 等人（2017））。广泛的覆盖范围使 GLUE 基准成为评估 RoBERTa 和 DeBERTa 等 NLU 模型的标准指标。各个数据集在不同的宽松许可证下发布。

WikiSQL 在 Zhong 等人（2017）中提出，包含 56, 355/8, 421 个训练/验证样本。任务是从自然语言问题和表模式生成 SQL 查询。我们将上下文编码为 $x = \{$表模式,查询$\}$，将目标编码为 $y = \{$SQL$\}$。该数据集在 BSD 3-Clause 许可证下发布。

SAMSum 在 Gliwa 等人（2019）中提出，包含 14, 732/819 个训练/测试示例。它由两人之间分阶段的聊天对话以及语言学家撰写的相应抽象摘要组成。我们将上下文编码为“\n”连接的语句，后跟一个“\n\n”，目标为$y = \{$summary$\}$。该数据集在非商业许可下发布：Creative Commons BY-NC-ND 4.0。

E2E NLG挑战赛首次在Novikova等人（2017）的工作中提出，作为一个用于训练端到端、数据驱动的自然语言生成系统的数据集，并且常用于数据到文本的评估。E2E数据集包含来自餐厅领域的大约42,000个训练样本、4,600个验证样本和4,600个测试样本。每个作为输入的源表格可以有多个参考文本。每个样本输入（x, y）由一系列槽位-值对以及相应的自然语言参考文本组成。该数据集在Creative Commons BY-NC-SA 4.0许可下发布。

DART 是 Nan 等人（2020）描述的一个开放领域数据到文本数据集。DART 的输入被构造为 ENTITY — RELATION — ENTITY 三元组序列。DART 总共有 82K 个示例，与 E2E 相比，它是一个显著更大且更复杂的数据到文本任务。该数据集在 MIT 许可证下发布。

WebNLG 是另一个常用于数据到文本评估的数据集（Gardent 等，2017）。WebNLG 总共包含 22K 个示例，涵盖 14 个不同类别，其中九个类别在训练期间可见。由于 14 个总类别中有五个在训练期间不可见，但在测试集中有代表，评估通常按“可见”类别（S）、“不可见”类别（U）和“全部”（A）分别进行。每个输入示例由一系列主语—属性—宾语三元组表示。该数据集在 Creative Commons BY-NC-SA 4.0 许可下发布。

D 实验中使用的超参数

D.1 ROBERTA

我们使用AdamW进行训练，并采用线性学习率衰减策略。我们对LoRA的学习率、训练轮数和批量大小进行了遍历。遵循Liu等人（2019）的方法，在适应MRPC、RTE和STS-B时，我们将LoRA模块初始化为我们最佳的MNLI检查点，而非通常的初始化方式；预训练模型在所有任务中保持冻结状态。我们报告了5个随机种子上的中位数；每次运行的结果取自最佳轮次。为了与Houlsby等人（2019）和Pfeiffer等人（2021）的设置进行公平比较，我们将模型序列长度限制为128，并对所有任务使用固定的批量大小。重要的是，在适应MRPC、RTE和STS-B时，我们从预训练的RoBERTa大型模型开始，而不是已经适应了MNLI的模型。使用此限制设置的运行标记为†。请参见表9中我们运行所使用的超参数。

D.2 DEBERTA

我们再次使用AdamW进行训练，并采用线性学习率衰减策略。遵循He等人（2021）的方法，我们调整学习率、dropout概率、预热步数和批量大小。我们使用与（He等人，2021）相同的模型序列长度，以保持比较的公平性。遵循He等人（2021）的方法，在适配MRPC、RTE和STS-B时，我们将LoRA模块初始化为我们最佳的MNLI检查点，而非通常的初始化方式；预训练模型在所有任务中保持冻结。我们报告5个随机种子上的中位数；每次运行的结果取自最佳epoch。我们在运行中使用的超参数见表10。

Method	Dataset	MNLI	SST-2	MRPC	CoLA	QNLI	QQP	RTE	STS-B
	Optimizer	AdamW							
	Warmup Ratio	0.06							
	LR Schedule	Linear							
RoBERTa base LoRA	Batch Size	16	16	16	32	32	16	32	16
	# Epochs	30	60	30	80	25	25	80	40
	Learning Rate	5E-04	5E-04	4E-04	4E-04	4E-04	5E-04	5E-04	4E-04
	LoRA Config.	$r_q = r_v = 8$							
	LoRA α	8							
	Max Seq. Len.	512							
RoBERTa large LoRA	Batch Size	4	4	4	4	4	4	8	8
	# Epochs	10	10	20	20	10	20	20	30
	Learning Rate	3E-04	4E-04	3E-04	2E-04	2E-04	3E-04	4E-04	2E-04
	LoRA Config.	$r_q = r_v = 8$							
	LoRA α	16							
	Max Seq. Len.	128	128	512	128	512	512	512	512
RoBERTa large LoRA†	Batch Size	4							
	# Epochs	10	10	20	20	10	20	20	10
	Learning Rate	3E-04	4E-04	3E-04	2E-04	2E-04	3E-04	4E-04	2E-04
	LoRA Config.	$r_q = r_v = 8$							
	LoRA α	16							
	Max Seq. Len.	128							
RoBERTa large Adpt^{P} (3M)†	Batch Size	32							
	# Epochs	10	20	20	20	10	20	20	20
	Learning Rate	3E-05	3E-05	3E-04	3E-04	3E-04	3E-04	3E-04	3E-04
	Bottleneck r	64							
	Max Seq. Len.	128							
RoBERTa large Adpt^{P} (0.8M)†	Batch Size	32							
	# Epochs	5	20	20	20	10	20	20	20
	Learning Rate	3E-04	3E-04	3E-04	3E-04	3E-04	3E-04	3E-04	3E-04
	Bottleneck r	16							
	Max Seq. Len.	128							
RoBERTa large Adpt^{H} (6M)†	Batch Size	32							
	# Epochs	10	5	10	10	5	20	20	10
	Learning Rate	3E-05	3E-04	3E-04	3E-04	3E-04	3E-04	3E-04	3E-04
	Bottleneck r	64							
	Max Seq. Len.	128							
RoBERTa large Adpt^{H} (0.8M)†	Batch Size	32							
	# Epochs	10	5	10	10	5	20	20	10
	Learning Rate	3E-04	3E-04	3E-04	3E-04	3E-04	3E-04	3E-04	3E-04
	Bottleneck r	8							
	Max Seq. Len.	128							

表9：T　我们用于RoBERTa在GLUE基准上的超参数　　hmark。

D.3 GPT-2

我们使用AdamW（Loshchilov & Hutter, 2017）训练所有GPT-2模型，采用线性学习率调度，共训练5个epoch。我们使用Li & Liang（2021）中描述的批量大小、学习率和束搜索的束大小。相应地，我们也为LoRA调整上述超参数。我们报告3个随机种子上的平均值；每次运行的结果取自最佳epoch。GPT-2中LoRA所使用的超参数列于表11。关于其他基线所使用的超参数，请参见Li & Liang（2021）。

D.4 GPT-3

对于所有GPT-3实验，我们使用AdamW（Loshchilov & Hutter, 2017）进行训练，共2个epoch，批量大小为128个样本，权重衰减因子为0.1。我们使用的序列长度为384，用于

Method	Dataset	MNLI	SST-2	MRPC	CoLA	QNLI	QQP	RTE	STS-B
	Optimizer	AdamW							
	Warmup Ratio	0.1							
	LR Schedule	Linear							
DeBERTa XXL LoRA	Batch Size	8	8	32	4	6	8	4	4
	# Epochs	5	16	30	10	8	11	11	10
	Learning Rate	1E-04	6E-05	2E-04	1E-04	1E-04	1E-04	2E-04	2E-04
	Weight Decay	0	0.01	0.01	0	0.01	0.01	0.01	0.1
	CLS Dropout	0.15	0	0	0.1	0.1	0.2	0.2	0.2
	LoRA Config.	$r_q = r_v = 8$							
	LoRA α	8							
	Max Seq. Len.	256	128	128	64	512	320	320	128

表10：DeBERTa XXL在GLUE基准测试所包含任务上的超参数。

Dataset	E2E	WebNLG	DART
	Training		
Optimizer	AdamW		
Weight Decay	0.01	0.01	0.0
Dropout Prob	0.1	0.1	0.0
Batch Size	8		
# Epoch	5		
Warmup Steps	500		
Learning Rate Schedule	Linear		
Label Smooth	0.1	0.1	0.0
Learning Rate	0.0002		
Adaptation	$r_q = r_v = 4$		
LoRA α	32		
	Inference		
Beam Size	10		
Length Penalty	0.9	0.8	0.8
no repeat ngram size	4		

表11：GPT-2 LoRA在E2E、WebNLG和DART上的超参数。

WikiSQL（Zhong等，2017），MNLI为768（Williams等，2018），SAMSum为2048（Gliwa等，2019）。我们为所有方法-数据集组合调整学习率。有关所用超参数的更多详细信息，请参见D.4节。对于前缀嵌入调优，我们发现最优的l_p和l_i分别为256和8，总计3.2M个可训练参数。我们使用$l_p = 8$和$l_i = 8$进行前缀层调优，具有20.2M个可训练参数，以获得整体最佳性能。我们为LoRA提出了两种参数预算：4.7M（$r_q = r_v = 1$或$r_v = 2$）和37.7M（$r_q = r_v = 8$或$r_q = r_k = r_v = r_o = 2$）。我们报告每次运行的最佳验证性能。我们的GPT-3实验中使用的训练超参数列于表12中。

E 将LORA与前缀调优相结合

LoRA 可以自然地与现有的基于前缀的方法结合。在本节中，我们在 WikiSQL 和 MNLI 上评估了 LoRA 与前缀调优变体的两种组合。

LoRA+PrefixEmbed（LoRA+PE）将LoRA与前缀嵌入调优相结合，其中我们插入$l_p + l_i$个特殊token，其嵌入被视为可训练参数。关于前缀嵌入调优的更多内容，请参见第5.1节。

LoRA+PrefixLayer（LoRA+PL）将LoRA与前缀层调优相结合。我们还插入了$l_p + l_i$个特殊token；然而，我们并未让这些token的隐藏表示自然演化——

Hyperparameters	Fine-Tune	PreEmbed	PreLayer	BitFit	Adapter^{H}	LoRA
Optimizer	AdamW					
Batch Size	128					
# Epoch	2					
Warmup Tokens	250,000					
LR Schedule	Linear					
Learning Rate	5.00E-06	5.00E-04	1.00E-04	1.6E-03	1.00E-04	2.00E-04

表12：用于不同GPT-3适配方法的训练超参数。在调整学习率后，我们对所有数据集使用相同的超参数。

集会后，我们在每个Transformer块之后用一个与输入无关的向量替换它们。因此，嵌入和后续Transformer块的激活都被视为可训练参数。关于前缀层调优的更多内容，请参见第5.1节。

在表15中，我们展示了LoRA+PE和LoRA+PL在WikiSQL和MultiNLI上的评估结果。首先，LoRA+PE在WikiSQL上显著优于LoRA和前缀嵌入调优，这表明LoRA与前缀嵌入调优在某种程度上是正交的。在MultiNLI上，LoRA+PE的组合表现并不优于LoRA，这可能是因为LoRA本身已经达到了与人类基线相当的性能。其次，我们注意到，即使LoRA+PL具有更多可训练参数，其表现也略逊于LoRA。我们将此归因于前缀层调优对学习率的选择非常敏感，从而使得在LoRA+PL中优化LoRA权重变得更加困难。

F 附加实证实验

F.1 关于GPT-2的额外实验

我们还在DART（Nan等，2020）和WebNLG（Gardent等，2017）上重复了我们的实验，遵循Li & Liang（2021）的设置。结果如表13所示。与我们在第5节中报告的E2E NLG Challenge上的结果类似，在相同的可训练参数数量下，LoRA的表现优于或至少与基于前缀的方法持平。

Method	# Trainable Parameters	DART BLEU↑	DART MET↑	DART TER↓
GPT-2 Medium				
Fine-Tune	354M	46.2	**0.39**	**0.46**
Adapter^{L}	0.37M	42.4	0.36	0.48
Adapter^{L}	11M	45.2	0.38	**0.46**
FT^{Top2}	24M	41.0	0.34	0.56
PrefLayer	0.35M	46.4	0.38	**0.46**
LoRA	0.35M	**47.1**$_{\pm.2}$	**0.39**	**0.46**
GPT-2 Large				
Fine-Tune	774M	47.0	**0.39**	0.46
Adapter^{L}	0.88M	45.7$_{\pm.1}$	0.38	0.46
Adapter^{L}	23M	47.1$_{\pm.1}$	**0.39**	**0.45**
PrefLayer	0.77M	46.7	0.38	**0.45**
LoRA	0.77M	**47.5**$_{\pm.1}$	**0.39**	**0.45**

表13：GPT-2在DART上采用不同适应方法。对于所有适应方法，MET和TER的方差均小于0.01。

Method	WebNLG								
	BLEU↑			MET↑			TER↓		
	U	S	A	U	S	A	U	S	A
	GPT-2 Medium								
Fine-Tune (354M)	27.7	**64.2**	46.5	.30	**.45**	.38	.76	**.33**	.53
Adapter^{L} (0.37M)	45.1	54.5	50.2	.36	.39	.38	.46	.40	.43
Adapter^{L} (11M)	**48.3**	60.4	54.9	**.38**	.43	**.41**	**.45**	.35	**.39**
FT^{Top2} (24M)	18.9	53.6	36.0	.23	.38	.31	.99	.49	.72
Prefix (0.35M)	45.6	62.9	55.1	**.38**	.44	**.41**	.49	.35	.40
LoRA (0.35M)	$46.7_{\pm.4}$	$62.1_{\pm.2}$	$\mathbf{55.3}_{\pm.2}$	**.38**	.44	**.41**	.46	**.33**	**.39**
	GPT-2 Large								
Fine-Tune (774M)	43.1	65.3	55.5	.38	**.46**	.42	.53	.33	.42
Adapter^{L} (0.88M)	$\mathbf{49.8}_{\pm.0}$	$61.1_{\pm.0}$	$56.0_{\pm.0}$	.38	.43	.41	**.44**	.35	.39
Adapter^{L} (23M)	$49.2_{\pm.1}$	$64.7_{\pm.2}$	$\mathbf{57.7}_{\pm.1}$	**.39**	**.46**	**.43**	.46	.33	.39
Prefix (0.77M)	47.7	63.4	56.3	**.39**	.45	.42	.48	.34	.40
LoRA (0.77M)	$48.4_{\pm.3}$	$64.0_{\pm.3}$	$57.0_{\pm.1}$	**.39**	.45	.42	.45	**.32**	**.38**

表14：GPT-2在WebNLG上采用不同适应方法的表现。在我们运行的所有实验中，MET和TER的方差均小于0.01。“U”表示未见类别，“S”表示已见类别，“A”表示WebNLG测试集中的所有类别。

F.2 关于GPT-3的附加实验

我们在表15中展示了GPT-3上采用不同适应方法的额外运行结果。重点是识别性能与可训练参数数量之间的权衡。

F.3 低数据量情形

为了评估不同适应方法在低数据情况下的性能，我们从MNLI的完整训练集中随机抽取100、1k和10k个训练样本，构成低数据MNLI-n任务。在表16中，我们展示了不同适应方法在MNLI-n上的性能。令我们惊讶的是，PrefixEmbed和PrefixLayer在MNLI-100数据集上表现非常差，其中PrefixEmbed的表现仅略好于随机猜测（37.6%对33.3%）。PrefixLayer的表现优于PrefixEmbed，但在MNLI-100上仍显著劣于Fine-Tune或LoRA。随着训练样本数量的增加，基于前缀的方法与LoRA/微调之间的差距变小，这可能表明基于前缀的方法不适合GPT-3中的低数据任务。LoRA在MNLI-100和MNLI-Full上均取得了优于微调的性能，并且在考虑由于随机种子导致的（±0.3）方差时，在MNLI-1k和MNLI-10K上取得了可比的结果。

不同适配方法在MNLI-n上的训练超参数报告在表17中。对于MNLI-100集上的PrefixLayer，我们使用较小的学习率，因为使用较大学习率时训练损失不会下降。

G 测量子空间之间的相似性

在本文中，我们使用度量$\phi(A, B, i, j) = \psi(U_A^i, U_B^j) = \frac{\|U_A^{i\top} U_B\|_F^2}{\min\{i,j\}}$来衡量两个列正交矩阵$U_A^i \in \mathbb{R}^{d\times i}$和$U_B^j \in \mathbb{R}^{d\times j}$之间的子空间相似性，这两个矩阵分别通过取$A$和$B$的左奇异矩阵的列得到。我们指出，这种相似性仅仅是衡量子空间之间距离的标准投影度量Ham & Lee (2008)的反向。

Method	Hyperparameters	# Trainable Parameters	WikiSQL	MNLI-m
Fine-Tune	-	175B	73.8	89.5
PrefixEmbed	$l_p = 32, l_i = 8$	0.4 M	55.9	84.9
	$l_p = 64, l_i = 8$	0.9 M	58.7	88.1
	$l_p = 128, l_i = 8$	1.7 M	60.6	88.0
	$l_p = 256, l_i = 8$	3.2 M	63.1	88.6
	$l_p = 512, l_i = 8$	6.4 M	55.9	85.8
PrefixLayer	$l_p = 2, l_i = 2$	5.1 M	68.5	89.2
	$l_p = 8, l_i = 0$	10.1 M	69.8	88.2
	$l_p = 8, l_i = 8$	20.2 M	70.1	89.5
	$l_p = 32, l_i = 4$	44.1 M	66.4	89.6
	$l_p = 64, l_i = 0$	76.1 M	64.9	87.9
$\text{Adapter}^{\text{H}}$	$r = 1$	7.1 M	71.9	89.8
	$r = 4$	21.2 M	73.2	91.0
	$r = 8$	40.1 M	73.2	91.5
	$r = 16$	77.9 M	73.2	91.5
	$r = 64$	304.4 M	72.6	91.5
LoRA	$r_v = 2$	4.7 M	73.4	**91.7**
	$r_q = r_v = 1$	4.7 M	73.4	91.3
	$r_q = r_v = 2$	9.4 M	73.3	91.4
	$r_q = r_k = r_v = r_o = 1$	9.4 M	74.1	91.2
	$r_q = r_v = 4$	18.8 M	73.7	91.3
	$r_q = r_k = r_v = r_o = 2$	18.8 M	73.7	**91.7**
	$r_q = r_v = 8$	37.7 M	73.8	**91.6**
	$r_q = r_k = r_v = r_o = 4$	37.7 M	74.0	**91.7**
	$r_q = r_v = 64$	301.9 M	73.6	91.4
	$r_q = r_k = r_v = r_o = 64$	603.8 M	73.9	91.4
LoRA+PE	$r_q = r_v = 8, l_p = 8, l_i = 4$	37.8 M	75.0	91.4
	$r_q = r_v = 32, l_p = 8, l_i = 4$	151.1 M	**75.9**	91.1
	$r_q = r_v = 64, l_p = 8, l_i = 4$	302.1 M	**76.2**	91.3
LoRA+PL	$r_q = r_v = 8, l_p = 8, l_i = 4$	52.8 M	72.9	90.2

表15：在WikiSQL和MNLI上不同适应方法的超参数分析。随着可训练参数数量的增加，前缀嵌入调优（PrefixEmbed）和前缀层调优（PrefixLayer）的表现均变差，而LoRA的性能则趋于稳定。性能以验证准确率衡量。

Method	MNLI(m)-100	MNLI(m)-1k	MNLI(m)-10k	MNLI(m)-392K
GPT-3 (Fine-Tune)	60.2	**85.8**	88.9	89.5
GPT-3 (PrefixEmbed)	37.6	75.2	79.5	88.6
GPT-3 (PrefixLayer)	48.3	82.5	85.9	89.6
GPT-3 (LoRA)	**63.8**	85.6	**89.2**	**91.7**

表16：使用GPT-3 175B在不同方法在MNLI子集上的验证准确率。MNLI-n描述了一个包含n个训练样本的子集。我们使用完整的验证集进行评估。与其他方法（包括微调）相比，LoRA表现出良好的样本效率。

具体来说，设 $U_A^{i\top} U_B^j$ 的奇异值为 $\sigma_1, \sigma_2, \cdots, \sigma_p$，其中 $p = \min\{i, j\}$。我们知道投影度量 Ham & Lee (2008) 定义为：

$$d(U_A^i, U_B^j) = \sqrt{p - \sum_{i=1}^{p} \sigma_i^2} \in [0, \sqrt{p}]$$

Hyperparameters	Adaptation	MNLI-100	MNLI-1k	MNLI-10K	MNLI-392K
Optimizer	-	AdamW			
Warmup Tokens	-	250,000			
LR Schedule	-	Linear			
Batch Size	-	20	20	100	128
# Epoch	-	40	40	4	2
Learning Rate	FineTune	5.00E-6			
	PrefixEmbed	2.00E-04	2.00E-04	4.00E-04	5.00E-04
	PrefixLayer	5.00E-05	5.00E-05	5.00E-05	1.00E-04
	LoRA	2.00E-4			
Adaptation-Specific	PrefixEmbed l_p	16	32	64	256
	PrefixEmbed l_i	8			
	PrefixTune	$l_p = l_i = 8$			
	LoRA	$r_q = r_v = 8$			

表17：在MNLI(m)-n上不同GPT-3适应方法所使用的超参数。

其中我们的相似性定义为:

$$\phi(A, B, i, j) = \psi(U_A^i, U_B^j) = \frac{\sum_{i=1}^{p} \sigma_i^2}{p} = \frac{1}{p}\left(1 - d(U_A^i, U_B^j)^2\right)$$

这种相似度满足：如果 U_A^i 和 U_B^j 共享相同的列空间，则 $\phi(A, B, i, j) = 1$。如果它们完全正交，则 $\phi(A, B, i, j) = 0$。否则，$\phi(A, B, i, j) \in (0, 1)$。

H 关于低秩矩阵的附加实验

我们展示了关于低秩更新矩阵研究的额外结果。

H.1 LORA 模块之间的相关性

参见图6和图7，了解图3和图4中呈现的结果如何推广到其他层。

H.2 r 对 GPT-2 的影响

我们在GPT-2上重复了关于r (第7.2节)效果的实验。以E2E NLG Challenge数据集为例，我们报告了训练26,000步后不同r选择所达到的验证损失和测试指标。我们在表18中展示了结果。GPT-2 Medium的最优秩根据所使用的指标在4到16之间，这与GPT-3 175B的情况相似。需要注意的是，模型大小与适应最优秩之间的关系仍是一个开放问题。

H.3 W与ΔW之间的相关性

参见图8　对于W和ΔW之间的归一化子空间相似度w　随着变化的 r。

再次注意，ΔW 不包含 W 的顶部奇异方向，因为 ΔW 中前4个方向与 W 中前10%方向之间的相似度仅略高于0.2。这提供了证据，表明 ΔW 包含那些“任务特定”的方向，而这些方向在 W 中 otherwise 被 *not* 强调。

一个有趣的后续问题是，我们需要多“强”地放大这些任务特定方向，才能使模型适配良好?

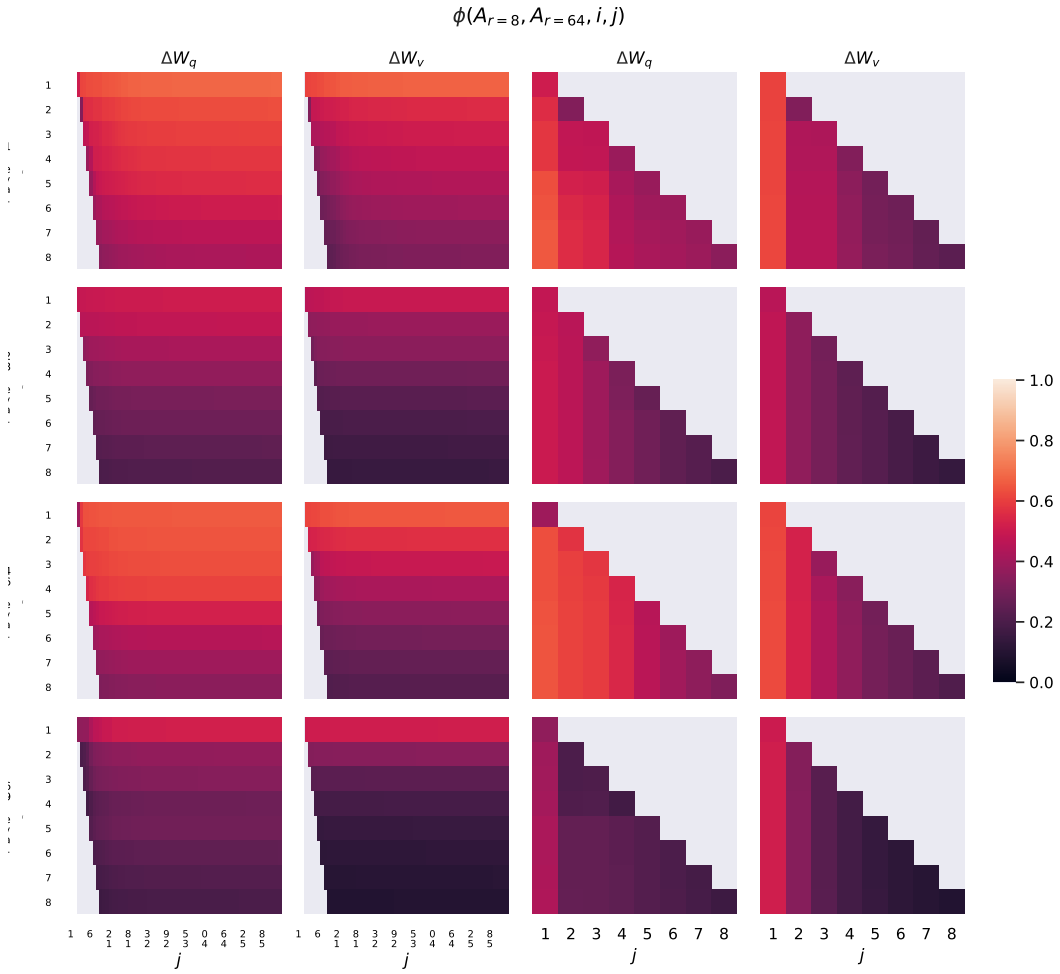


图6：在96层Transformer中，第1、32、64和96层中$A_{r=8}$和$A_{r=64}$的列向量之间分别与ΔW_q和ΔW_v的归一化子空间相似度。

H.4 放大因子

人们自然可以将 *feature amplification factor* 视为 *ratio* $\frac{\|\Delta W\|_F}{\|U^\top W V^\top\|_F}$，其中 U 和 V 是 ΔW 的 SVD 分解的左奇异矩阵和右奇异矩阵。（回想 $UU^\top W V^\top V$ 给出了 W 在由 ΔW 张成的子空间上的“投影”。）

直观地说，当 ΔW 主要包含任务特定方向时，这个量衡量了其中有多少被 ΔW 放大。如第 7.3 节所示，对于 $r = 4$，这个放大因子高达 20。换句话说，（一般来说）每一层中有四个特征方向（在预训练模型 W 的整个特征空间中），需要被一个非常大的因子 20 放大，才能达到我们报告的针对下游特定任务的准确率。而且，对于每个不同的下游任务，应该预期会放大一组非常不同的特征方向。

然而，人们可能会注意到，对于 $r = 64$，这个放大因子仅在 2 左右，这意味着在 ΔW 中学习到的 *most* 方向，当 $r =$ 为 64 时，*not* 被大幅放大。这并不令人意外，事实上（再次）提供了证据，表明用于表示“任务特定方向”（因而用于模型适配）的内在秩 *needed* 是较低的。相比之下，在 ΔW (的秩为 4 的版本中，对应于 $r = 4$) 的那些方向被一个更大的因子 20 放大。

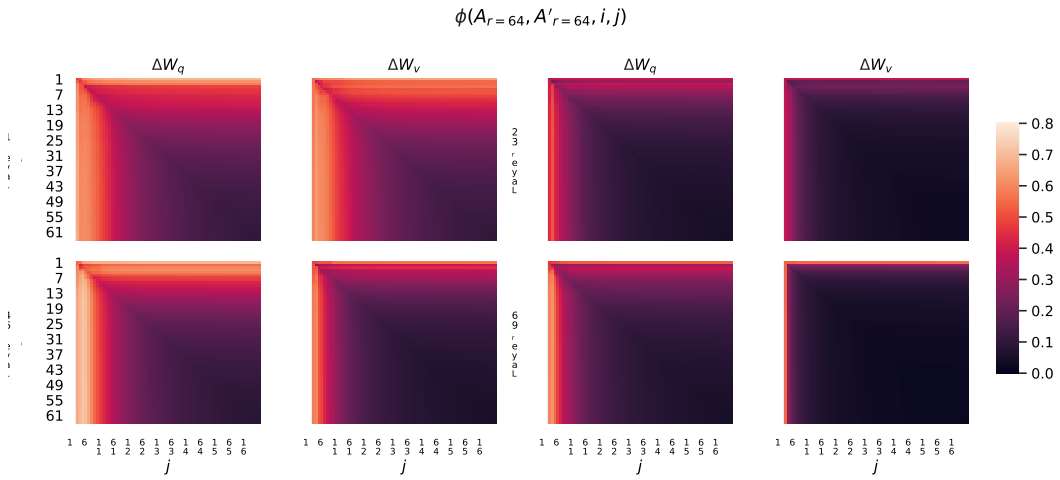


图7：在96层Transformer中，来自两个随机种子运行的$A_{r=64}$列向量之间的归一化子空间相似度，分别针对第1、32、64和96层的ΔW_q和ΔW_v。

Rank r	val_loss	BLEU	NIST	METEOR	ROUGE_L	CIDEr
1	1.23	68.72	8.7215	0.4565	0.7052	2.4329
2	1.21	69.17	8.7413	0.4590	0.7052	2.4639
4	1.18	**70.38**	**8.8439**	**0.4689**	0.7186	**2.5349**
8	1.17	69.57	8.7457	0.4636	**0.7196**	2.5196
16	**1.16**	69.61	8.7483	0.4629	0.7177	2.4985
32	**1.16**	69.33	8.7736	0.4642	0.7105	2.5255
64	**1.16**	69.24	8.7174	0.4651	0.7180	2.5070
128	**1.16**	68.73	8.6718	0.4628	0.7127	2.5030
256	**1.16**	68.92	8.6982	0.4629	0.7128	2.5012
512	**1.16**	68.78	8.6857	0.4637	0.7128	2.5025
1024	1.17	69.37	8.7495	0.4659	0.7149	2.5090

表 18：使用 GPT-2 Medium 的 LoRA 在不同秩 r 下于 E2E NLG Challenge 上取得的验证损失和测试集指标。与 GPT-3 上 $r = 1$ 对许多任务已足够不同，此处性能在验证损失上于 $r = 16$ 达到峰值，在 BLEU 上于 $r = 4$ 达到峰值，这表明与 GPT-3 175B 相比，GPT-2 Medium 在适配方面具有相似的内在秩。请注意，我们的一些超参数是在 $r = 4$ 上调优的，这与另一个基线的参数数量相匹配，因此对于 r 的其他选择可能并非最优。

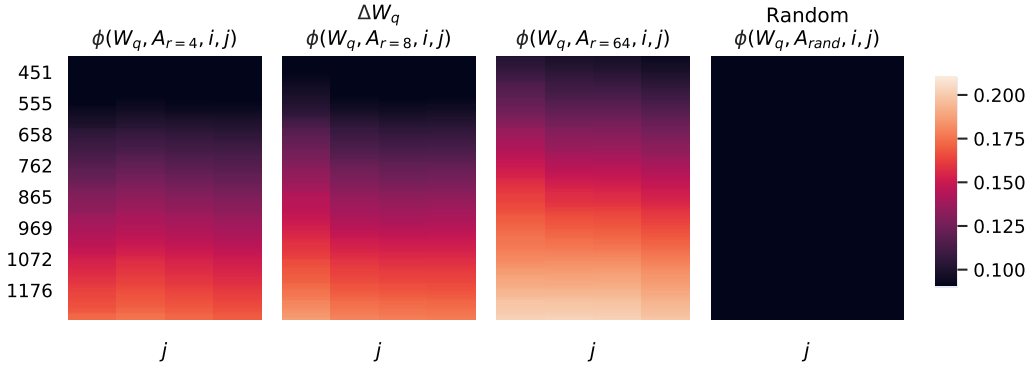


图8：W_q的奇异方向与ΔW_q的奇异方向之间的归一化子空间相似度，随r变化，并包含随机基线。ΔW_q放大了重要但在W中未被强调的方向。具有较大r的ΔW倾向于选取更多在W中已被强调的方向。